Caches de disco
Page cache & buffer cache

Diseño de Sistemas Operativos

Grado en Ing. de Computadores, 3er Curso

Depto. de Arquitectura de Computadores
Universidad de Málaga

Contenidos

- Discos: dispositivos de bloques
- Caches de disco
- Page Cache (ficheros)
- Buffer Cache (bloques)
- Lectura/escritura buffers (bloques)
- Escritura de páginas a disco
- Planificación de E/S
  - Peticiones de E/S
  - “Ascensor” de linux

Dispositivos de bloques

- Discos duros, Blue-ray, memoria flash, etc.
  - Se accede a bloques de datos de tamaño fijo
  - Acceso aleatorio (random access)
  - Se accede directamente a los bloques de disco (raw) o mediante un sistema de ficheros
  - Operaciones: open, read, write, seek, sync,….
  - Es posible mapear en memoria un fichero y acceder como a un array de memoria
- Dispositivos de carácteres son más sencillos de gestionar (teclado, puertos serie, …)
  - se accede a un stream linealmente

Caches para acceso a disco

- Cache de disco
  - El sistema mantiene en memoria datos del disco
  - Los datos son accedidos rápidamente sin tener que ir al disco
  - Localidad en accesos a disco
    - Del mismo proceso
    - Procesos diferentes
  - Crucial para rendimiento

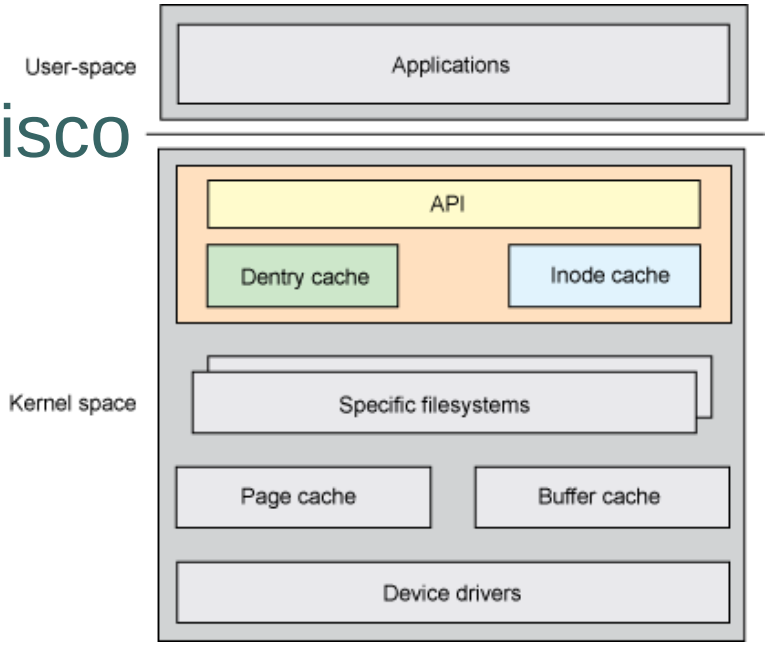

Caches para acceso a disco

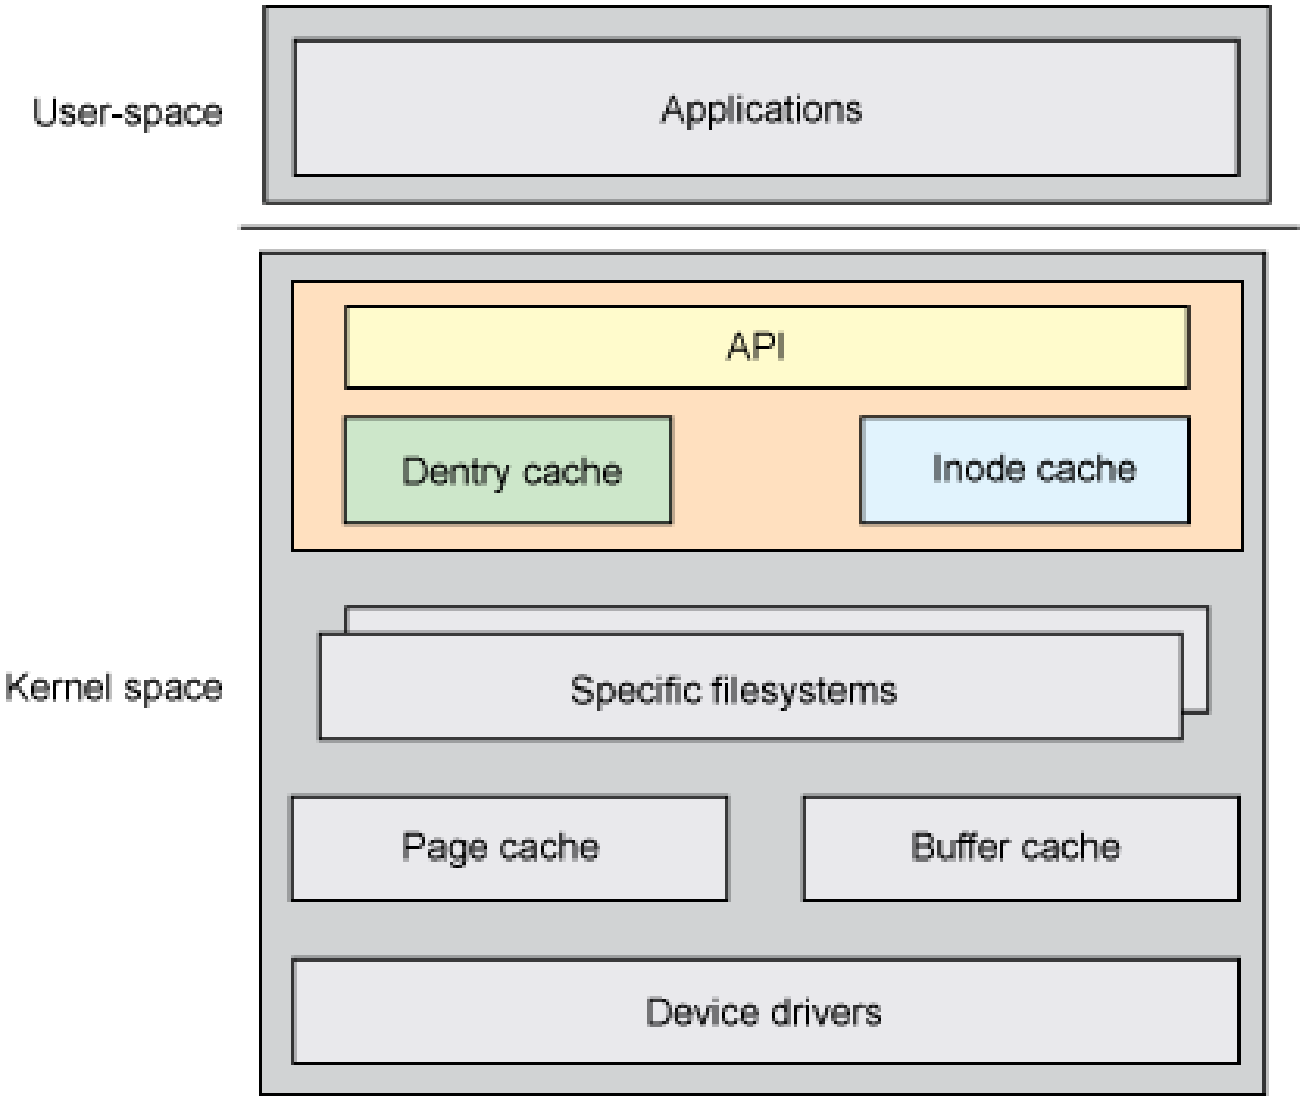

Page cache (ficheros)

- Es la cache de disco principal en linux
- Se usa para **leer y escribir** en disco
  - Páginas completas de memoria
  - Corresponden a trozos de ficheros
- Las páginas se mantienen en la cache mientras se pueda
- Se escriben a disco lo más tarde posible
  - Escritura diferida
- Es posible lectura adelantada en ficheros
  - Precarga

Page cache

- Contenido de la page cache
  - Páginas de ficheros
  - Páginas de directorios (son ficheros)
  - Páginas con datos de bloques de disco (no forman parte de un fichero)
  - Páginas intercambiadas a disco
- Cada página pertenece a un fichero (o dispositivo)
  - Propietario de la página
- Si un fichero se abre con O_DIRECT
  - No se usa el page cache
  - El kernel no controla el buffer (se hace en espacio de usuario)

Organización del page cache

- Estructura address_space
  - Cada propietario (fichero/dispositivo) mantiene un address_space con todas sus páginas del page cache
- Las páginas están enlazadas en un radix-tree
  - Almacenamiento compacto
  - Búsquedas rápidas

Radix tree

- Se indexa cada página en el radix tree usando su posición en disco dentro del fichero
  - add_to_page_cache()
  - find_get_page()
- Se usan etiquetas en los nodos para comprobaciones rápidas
  - PG_dirty
  - PG_writeback

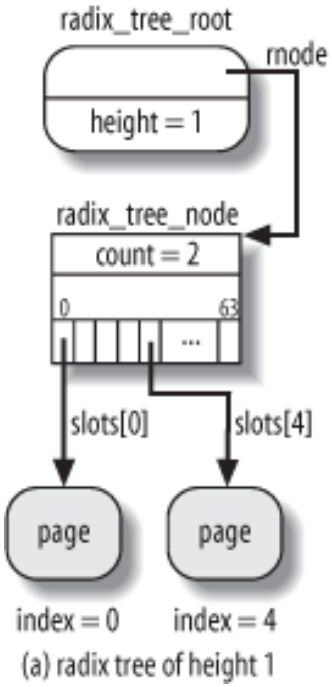

(a) radix tree of height 1

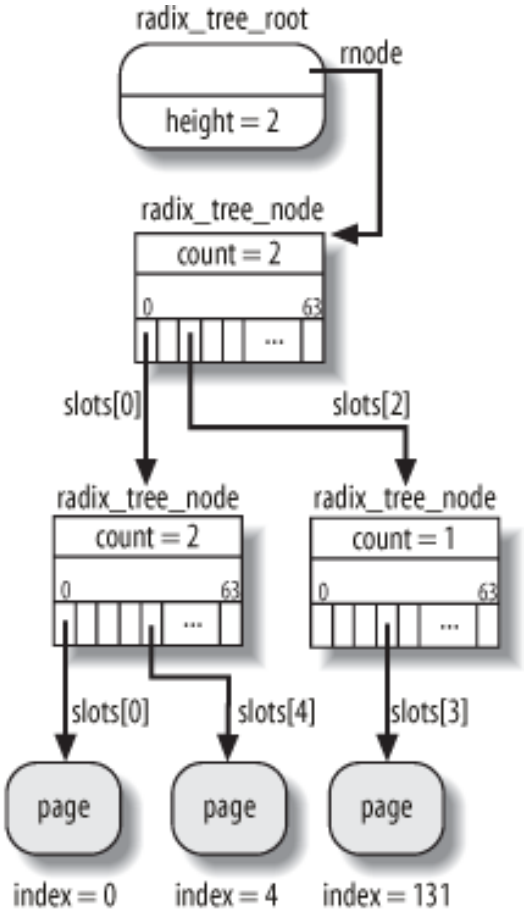

(b) radix tree of height 2

Acceso a los bloques en el page cache

- Las páginas que contienen bloques se integran en el address_space de su propietario (dispositivo)
- Se indexan en el radix tree por página así que hay que traducir la dirección en bloques a su dirección de página
- La página (si existe) mantiene un puntero a la lista de buffer_head donde puede estar el bloque que buscamos

Lectura de bloques

- Cada página mantendrá buffers para bloques de igual tamaño
  - x86: página 4KB contiene de 1 a 8 bloques
- Leer el bloque que contiene el inodo de un fichero (1KB) en disco
  - El kernel reserva una página (4KB) para cuatro bloques
  - Lee cuatro bloques adyacentes en disco
  - Uno de ellos es el inodo que necesitamos

Escritura de páginas a disco

- La page cache se llena sin cesar
- Algunas páginas son modificadas PG_dirty
- El kernel retrasa la escritura lo máximo posible, hasta:
  - La page cache está muy llena
  - Hay demasiadas PG_dirty
  - Demasiado tiempo en PG_dirty
    - vamos a perder datos si no grabamos!
  - Un proceso pide el flush
    - sync() fsync() fdatasync()
- Para los buffers de bloques la página esta dirty si alguno de sus buffers lo está

Escritura de páginas a disco

- Kernel threads **pdflush**
  - Escanean la page cache en busca de páginas dirty que volcar a disco
  - Entre 2 y 8 threads tabajando según la carga
  - Los threads flusher se activan cada cierto tiempo para comprobar. También se lanza cuando la memoria está baja o cuando lo pide el usuario

    wakeup_flusher_threads()
  - Modo laptop

Configuración escritura págs.

Variable	Descripción
dirty_background_ratio	Porcentaje de memoria total a partir del cual los threads flushers empiezan a escribir páginas dirty a disco
dirty_expire_centisecs	Antigüedad para que una página sea escrita a disco la próxima vez que se despierte el thread para comprobar (periódicamente)
dirty_ratio	Igual que el primero pero para un solo proceso
dirty_writeback_centisecs	Intervalo de tiempo que pasa entre cada activación (wake up) de los thread flushers
laptop_mode	1 para activar el modo laptop 0 para desactivarlo

Configurable en /proc/sys/vm o con sysclt()

Accediendo a un dispositivo por bloques

- De ficheros hay que pasar a bloques
- Para leer y escribir bloques se usan buffers
- También usamos una cache de buffers

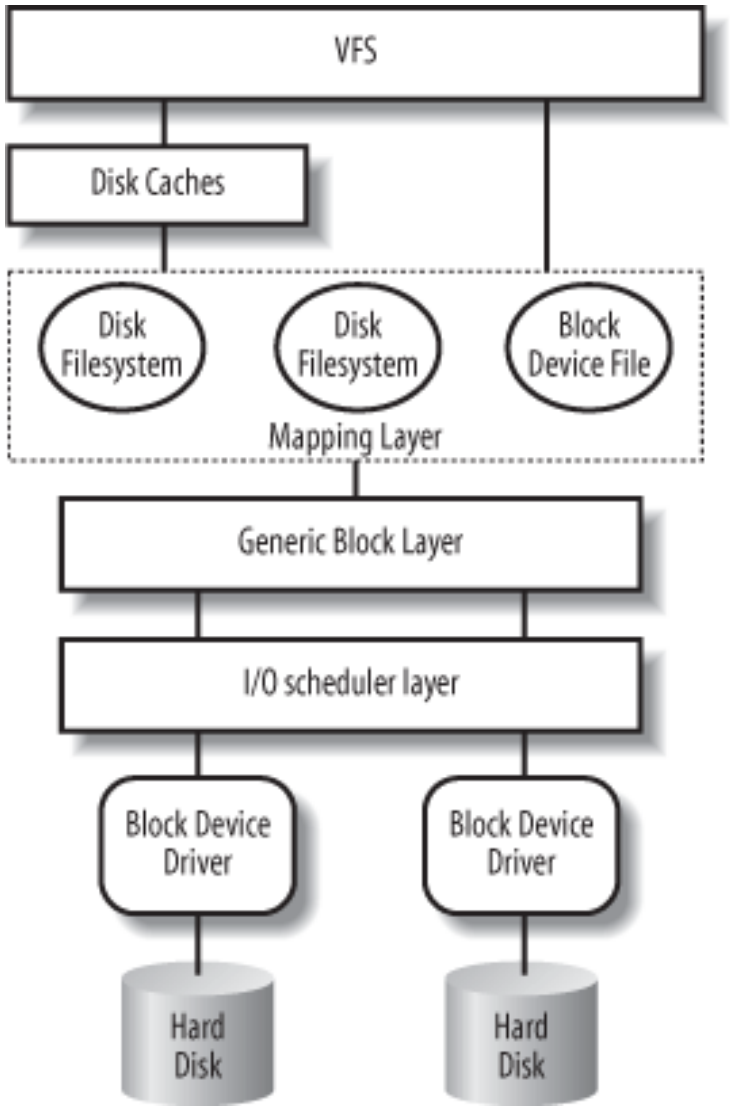

Buffer cache (bloques E/S)

- Pool de buffers para transferencias de E/S en marcha y recientes (cacheadas)
- Cada buffer se compone de:
  - datos (el propio buffer) en una página del page cache
  - buffer_head (descriptor del buffer)
- Integrada en la page cache de linux desde kernel 2.4.10
- Buffers en páginas de memoria del *page cache*

Buffers en una página

- Sector
  - Unidad de transferencia del disco
- Bloque
  - Unidad de transferencia del sistema de ficheros
- Segmento
  - Región contigua de memoria en una operación de DMA
- Página
  - Unidad de asignación de memoria virtual

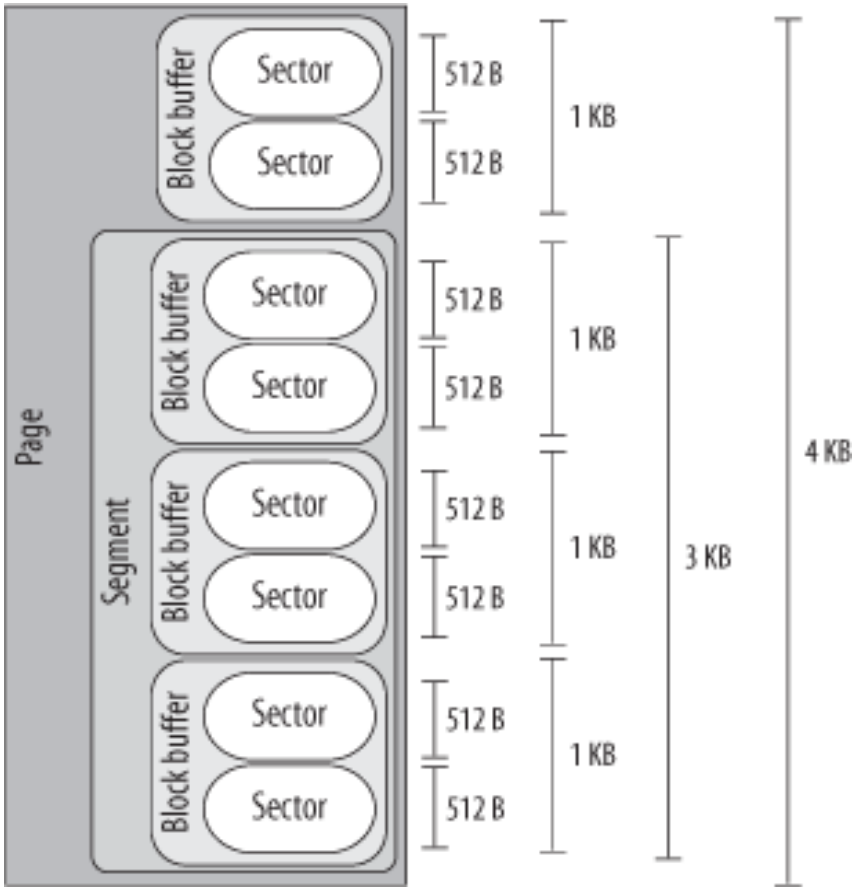

Buffer head

Type	Field	Description
unsigned long	b_state	Buffer status flags
struct buffer_head *	b_this_page	Pointer to the next element in the buffer page's list
struct page *	b_page	Pointer to the descriptor of the buffer page holding this block
atomic_t	b_count	Block usage counter
u32	b_size	Block size
sector_t	b_blocknr	Block number relative to the block device (logical block number)
char *	b_data	Position of the block inside the buffer page
struct block_device *	b_bdev	Pointer to block device descriptor
bh_end_io_t *	b_end_io	I/O completion method
void *	b_private	Pointer to data for the I/O completion method
struct list_head	b_assoc_buffers	Pointers for the list of indirect blocks associated with an inode

Páginas/buffers

- El kernel mantiene el conjunto de BHs de los buffers presentes en la cache

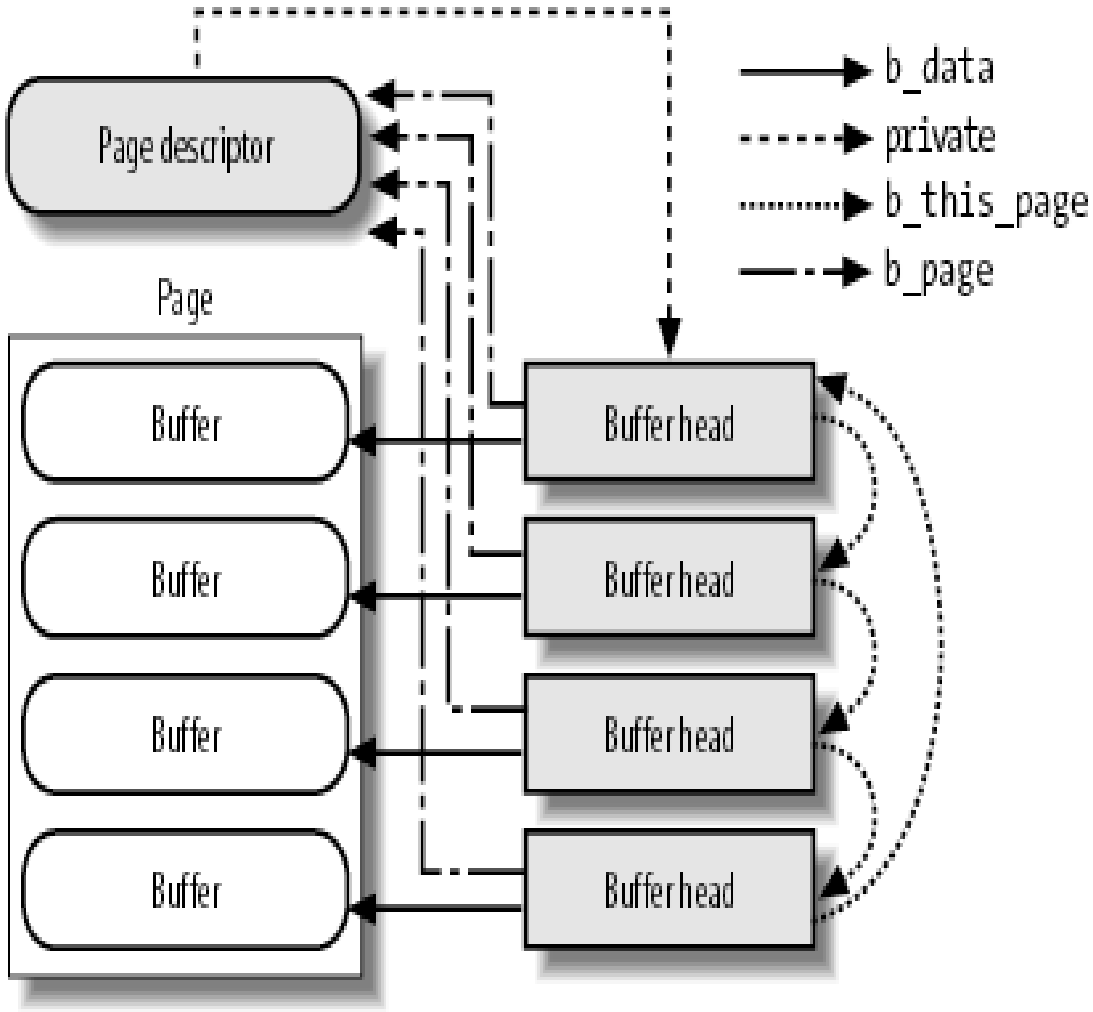

Accediendo a un dispositivo por bloques

- De ficheros hay que pasar a bloques
- Para leer y escribir bloques se usan buffers
- También usamos una cache de buffers

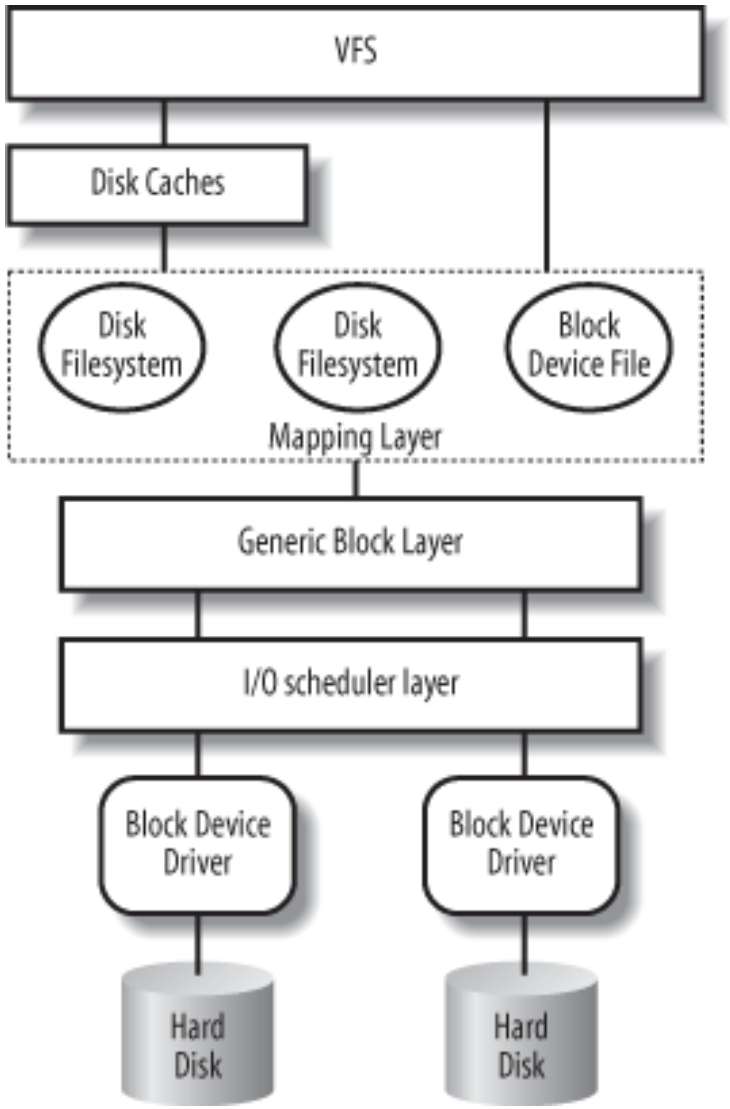

Peticiones de E/S

- La capa de acceso a bloques genérica (Generic Block Layer) resuelve las peticiones de lectura/escritura a disco
- Se basa en la estructura **bio** que describe la operación de E/S
  - Bloques de disco (dispositivo, bloques)
  - Segmentos de memoria (buffer_heads)
- Se realiza la petición de entrada/salida para la estructura **bio**
  - generic_make_request()

Planificador de E/S

- Cada petición de E/S contiene una estructura **bio** inicialmente
- No se ejecutan inmediatamente
- El planificador de E/S la encola e intenta unirla a otra petición de bloques adyacentes en la cola
- Además ordena las peticiones usando como criterio los sectores que acceden en disco

Ascensor de Linux (elevator)

- Diferentes estrategias para despachar las peticiones de E/S
- Básica: ascensor que no cambia de sentido hasta llegar a un extremo
- Noop (No Operation)
  - Sin reordenación
- CFQ (Complete Fairness Queueing)
  - RR entre diferentes procesos
  - Usualmente muchas colas (64) y se usa un hash sobre el PID para encolar en la cola correspondiente por orden de llegada las peticiones en las diferentes colas

Ascensor de Linux (elevator)

- Deadline
  - Las misma peticiones encoladas por dos sistemas en cuatro colas
  - 2 read/write ordenadas por sector
  - 2 read/write ordenadas por deadline (500ms lecturas y 5 s escrituras)
  - Se intentan primero las read (write si lleva mucho tiempo sin tocarle)
  - Después se mira si hay algún deadline cumplido sino sigue por orden donde estaba
  - Se despacha un lote, más grande si son contiguas

Ascensor de Linux (elevator)

- Anticipatory
  - Igual que deadline (125 ms para read, 250 ms para write)
  - Algunas veces cambia de sentido (cuando la distancia hacia atrás es menos de la mitad)
  - Algunas veces espera un poco (7 ms) a un proceso
    - Que repite un patrón de peticiones (acumular estadísticas de los procesos)

Configurar el planificador

- Configurable como root en los ficheros:
  /sys/block/{DEVICE-NAME}*/queue/scheduler*

```
#  cat /sys/block/sda/queue/scheduler
noop anticipatory deadline [cfq]
# echo noop > /sys/block/hda/queue/scheduler
# cat /sys/block/sda/queue/scheduler
[noop] anticipatory deadline cfq
```

Lecturas

- Understanding the Linux Kernel:
  - Capítulo 15. “Page cache” (completo)
  - Capítulo 14
    - Block Devices Handing
    - The Generic Block Layer
    - The I/O Scheduler
- Linux Kernel Development:
  - Capítulo 16. The Page cache and …
  - Capítulo 14. The Block I/O layer